

FAKE × TRUE

Vinagre: fase de generalização externa

Material de estudo: o que foi feito de 30/09 a 05/10/2026, por quê, e o que saiu de cada passo

O que tem aqui

Este material cobre **só a última etapa** do projeto: do ambiente reproduzido (E0) até o modelo escolhido e a avaliação final única, mais a análise de como o modelo funciona por dentro (06/10).

As etapas anteriores (atalho do tamanho no Fake.br, truncamento, mascaramento, split por fonte, FakeRecognize) aparecem só como ponto de partida.

Como estudar: leia as páginas 2–3 (visão geral e conceitos), depois cada experimento. No fim há **perguntas prováveis da banca com respostas** e uma **cola de uma página** com os números.

1. Visão geral da etapa

A pergunta desta etapa

O modelo da etapa anterior (TF-IDF de palavras + SVM, treinado em Fake.br + FakeRecogna) ia bem dentro dos datasets, mas a pergunta real era outra: **ele acerta notícias de verdade, de 2026, coletadas da internet, que nunca viu?** E, se não, **como melhorar isso sem trapacear olhando o teste?**

De onde saímos e aonde chegamos

Momento	Modelo	F1 macro	Onde foi medido
Início da etapa	Fake.br + FakeRecogna, TF-IDF palavras	82,9	validação externa (855 itens)
Depois dos dados (E4)	FakeRecogna 2020–21 + corpus externo, palavras	90,5	validação externa
Depois do modelo (E5–E6)	mesmos dados, TF-IDF de caracteres	91,4	validação externa
Avaliação final	modelo escolhido, congelado	94,2 [89–99]	testes 1 + 2 (116 itens novos)

A ideia central da etapa: o salto grande (+7,5 pontos) veio de **dados no formato certo** (o corpus externo). Trocar o modelo rendeu só ~1 ponto, dentro do empate técnico.

Linha do tempo

Etapa	Data	O que foi feito	Resultado em uma frase
E0	30/09	Ambiente e reprodução dos números de controle	94,15% e 89,88%: bateu com o notebook
E1	30/09	Coleta e conferência do teste externo (39 itens)	teste guardado, sem avaliar
E2	30/09–01/10	Coleta do corpus externo 2022–2026 (2.849 itens)	dados no formato do produto
E3	01/10	Modelos antigos na validação externa	ponto de partida: 79,9 e 82,9
E4	01/10	17 combinações de dados de treino	corpus externo é o que mais ajuda
E5	05/10	12 variações de representação/classificador	tudo empata entre 89 e 92
E6	05/10	Treinar sem uma fonte e testar nela	caracteres é o mais robusto
E7	05/10	Embeddings (e5-small, MiniLM)	e5 empata, mas é pesado
E8	05/10	Hipótese: true têm mais números	verdadeira, mas não ajuda o modelo
Escolha	05/10	Decisão + pré-registro	TF-IDF char_wb(2,5) + LinearSVC
Final	05/10	Avaliação única nos testes 1 e 2	F1 94,2; 100% das true corretas

2. Conceitos que você precisa dominar

Os três papéis dos dados (a regra mais importante)

Conjunto	Para que serve	Pode escolher coisas com ele?
Treino	o modelo aprende	—
Validação externa (855 itens)	comparar dados, modelos, hiperparâmetros	sim: todas as escolhas
Testes 1 e 2 (116 itens)	medir o modelo final uma vez	não, nunca

Se você escolhe o modelo olhando o teste, o número do teste deixa de ser uma estimativa honesta: você escolheu justamente o que deu sorte naquelas notícias. Isso se chama **vazamento (leakage)** ou **overfitting na validação**.

Métricas

- **Recall de uma classe:** das notícias que realmente são daquela classe, quantas o modelo acertou. Recall true 100% = nenhuma notícia verdadeira foi chamada de fake.
- **F1 de uma classe:** média harmônica de precisão e recall daquela classe.
- **F1 macro:** média simples do F1 das duas classes. Não favorece a classe maior. Foi a métrica principal porque o corpus externo tem 2× mais true que fake.
- **Balanced accuracy:** média dos recalls das duas classes. Também resiste a desbalanceamento.
- **Acurácia:** % de acertos total. Enganosa com classes desbalanceadas (o "só tamanho" da E8 dá recall true 100% e fake 9%).

Incerteza

- **IC 95% por bootstrap (F1):** sorteia 2.000 vezes os 116 itens com reposição, calcula o F1 de cada sorteio e pega os percentis 2,5 e 97,5. Resultado: 94,2 [89–99].
- **IC de Wilson (acurácia):** fórmula para intervalo de uma proporção, melhor que a normal quando n é pequeno.
- **Empate técnico:** regra do projeto: diferenças menores que ~1–2 pontos são empate, principalmente depois de testar ~40 configurações na mesma validação.

Outras ideias usadas

- **Pré-registro:** escrever *antes* de ver o teste quais modelos serão avaliados e como os resultados serão lidos. Impede ajustar a narrativa depois.
- **Avaliação única:** o script `avaliacao_final.py` avaliar se recusa a rodar se o arquivo de resultado já existe.
- **Descontaminação:** remover do corpus qualquer texto com similaridade de cosseno $\geq 0,8$ com algum texto do teste (sem olhar o rótulo).
- **Atalho (shortcut):** pista fácil que separa as classes no dataset mas não tem relação com o que se quer aprender (tamanho do texto, site de origem, época do assunto).
- **Supervisionado × não supervisionado:** o classificador (LinearSVC) é supervisionado, aprende com rótulos. O TF-IDF é não supervisionado: monta vocabulário e pesos sem olhar o rótulo. Não houve clustering.

3. Preparação: ambiente, teste e corpus (E0–E2)

E0 · Ambiente e reprodução

- **Ação:** Python 3.12, venv, **scikit-learn fixado em 1.6.1**.
- **Por quê:** os .joblib foram salvos nessa versão; com outra dá aviso de incompatibilidade, e a divisão dos folds do StratifiedGroupKFold muda entre versões.
- **Resultado:** só tamanho 94,15% (esperado 94,17); TF-IDF N=50 89,88% (esperado 89,88). Antes de qualquer experimento novo, provamos que o pipeline reproduz o anterior.

E1 · Teste externo (coletado, conferido, guardado)

- Coleta automática por RSS, sempre os itens mais recentes, **sem escolha manual**.
- True: Agência Brasil e G1 (início da matéria, até 60 palavras, **sem título**). Fake: Boatos.org e E-farsas (o boato citado na página).
- Conferência **só por conteúdo**, nunca pela previsão do modelo: 5 remoções (3 desmentidos oficiais do E-farsas e 2 traduções).
- Resultado: 39 itens. **Não avaliado** até o final.

Por que tirar o título das true? O trafilatura incluía o título na Agência Brasil e não no G1. Isso criaria uma diferença sistemática entre fontes que o modelo poderia usar como pista.

E2 · Corpus externo (a peça mais importante da etapa)

Problema: nenhum dataset disponível se parecia com o uso real. O Fake.br é de 2016–18 e tem 92,7% das fake de um único site. O FakeRecogna tem true que são resumos automáticos. Sem dados no formato do teste, não havia como medir nem melhorar o desempenho externo sem usar o próprio teste.

Solução: coletar um corpus das mesmas fontes, com páginas mais antigas dos feeds e outras editorias.

Split	Classe	Fonte	n	Período
treino	fake	Boatos.org	567	nov/2025 – jul/2026
treino	fake	E-farsas	78	mai/2022 – jul/2024
treino	true	G1	1.277	ago – out/2026
treino	true	Agência Brasil	72	set – out/2026
val	fake	Boatos.org / E-farsas	243 / 34	jul – set/2026 / 2024–26
val	true	G1 / Agência Brasil	547 / 31	ago – out/2026

- Funil: 4.284 brutos → 2.853 com mínimo de palavras → 2.849 sem duplicados → 2.849 após descontaminação.
- **Divisão 70/30:** nas fake, os 30% **mais recentes** de cada agência vão para validação (imita o uso real, em que o boato é sempre novo); nas true, 30% sorteados.
- Anti-contaminação: nenhum link do teste, página 1 dos feeds ignorada, feed Fato ou Fake do G1 excluído.
- Limitação: 940 páginas do Boatos.org e 459 do E-farsas não tinham texto (o boato era imagem ou vídeo).

Risco registrado já aqui: as fake de treino vão até jul/2026 e as true são todas de ago–out/2026. O modelo pode aprender "assunto do momento = true". O teste tem a mesma estrutura, então nem a validação nem o teste detectam esse atalho.

4. Dados: o que treinar (E3–E4)

E3 · Ponto de partida

Modelo antigo	F1	Rec. fake	Rec. true	E-farsas
Só Fake.br	79,9	66,4	91,2	35,3
Fake.br + FakeRecogna 2020–21 (candidato)	82,9	77,3	88,8	50,0

Validação externa, 855 itens, entrada de até 50 palavras.

E4 · Mesmo modelo, dados diferentes

Mantivemos o modelo fixo (TF-IDF palavras + LinearSVC balanceado, treino misto 30/50/100) e variamos só os dados. Assim, qualquer diferença vem dos dados. Siglas: **fb** = Fake.br; **fr2021** = FakeRecogna 2020–21; **frall** = FakeRecogna todos os anos; **ext** = treino do corpus externo.

Dados de treino	F1	Rec. fake	Rec. true	Leitura
fb	79,9	66,4	91,2	base
fr2021	75,1	79,1	75,6	
frall	69,2	79,8	65,7	atalho de época
ext	88,3	78,0	96,0	sozinho já supera tudo
fb + ext	87,6	76,9	95,7	Fake.br não soma
fr2021 + ext	90,5	83,8	95,7	escolhido
frall + ext (ext x3)	90,7	85,6	95,0	maior, mas empate
fb + fr2021 + ext	89,7	81,9	95,7	empate

Tabela resumida (17 combinações no total).

O que aprender com a E4

- **O corpus externo é o que mais ajuda:** sozinho vai de ~83 para 88,3.
- **O Fake.br não ajuda quando há o externo** (fb + ext $\approx$ ext).
- **frall sem o externo derruba o recall de true para ~66%:** as fake do FakeRecogna vão de 2013 a 2023 e as true estão em 2020–21. O modelo aprende "assunto de outra época = fake".
- Entre as combinações com ext, tudo fica entre 87,6 e 90,7: **empate técnico**.

Decisão: fr2021 + ext. Empata com o maior (90,47 $\times$ 90,69, diferença < 1 ponto) e é o mais simples: sem repetir o externo e sem depender do frall, que mostrou atalho de época. A alta do frall + ext x3 no E-farsas (73,5) é em só 34 itens e não sustenta a escolha.

5. Modelo: como representar o texto (E5–E7)

E5 · Doze variações, mesmos dados

Variação	F1	Rec. fake	Rec. true
word(1,2) C=1 [base]	90,5	83,8	95,7
word(1,2) C=0,1 / 0,3 / 3	90,3 / 90,5 / 89,6		
word(1,2) sublinear / min_df=2 / maiúsculas	89,8 / 89,9 / 89,8		
word(1,1)	89,4	83,4	94,5
char_wb(2,5)	91,4	85,2	96,2
word(1,2) + char_wb(2,5)	91,3	84,8	96,2
word + char_wb sem lowercase	92,3	86,3	96,7
Regressão logística word(1,2) C=10	90,1	83,4	95,3

Tudo entre 89,4 e 92,3. Os hiperparâmetros das palavras (C, sublinear, min_df) empatam com a base. As três variações com n-gramas de caracteres ficam no topo, mas dentro da faixa de empate. **Para desempatar, a E6.**

E6 · Robustez: treinar sem uma fonte e testar só nela

Pergunta: o modelo aprende "boato × jornalismo" ou só "site A × site B"? Treinamos sem uma fonte de cada classe e avaliamos só nessas fontes.

Treino	Sem E-farsas/Ag. Brasil (n=215)	Sem Boatos.org/G1 (n=2.634)
fr2021 (sem externo)	76,9	75,6
fr2021 + ext, palavras [base]	80,1	80,4
fr2021 + ext, char_wb(2,5)	80,2	83,0
fr2021 + ext, word + char sem lowercase	76,6	81,8

- O externo ajuda mesmo em fontes não vistas (+3 a +5): o ganho **não é só** assinatura de site.
- Mas a queda de ~90 para ~80 mostra que **parte é**.
- O primeiro da E5 (sem lowercase) perde 3,5 pontos em fonte nova: as **maiúsculas parecem estilo de cada site**. O char_wb(2,5) nunca fica abaixo da base.

E7 · Embeddings

Embedding + regressão logística	F1 (melhor C)	Observação
multilingual-e5-small	91,8 (C=10)	empata com char_wb; C na borda da grade
paraphrase-multilingual-MiniLM-L12-v2	87,0 (C=10)	abaixo da base TF-IDF

O e5-small empata, mas não passou pela E6 (robustez desconhecida), exige torch e um modelo de 470 MB, e foi treinado sem o aumento 30/50/100.

6. Uma hipótese testada: notícia verdadeira tem mais números? (E8)

Hipótese do responsável: notícia verdadeira cita mais datas, valores e quantidades, porque trata de fatos exatos. A feature é a **proporção** de palavras que são número (não a contagem).

Detalhe técnico, a suavização: em trecho curto o percentual cru é instável (1 número em 8 palavras = 12,5%). Usamos $pct_suave = (n_números + m \cdot p0) / (n_palavras + m)$, com $m = 20$ e $p0$ = média do treino. Com poucas palavras o valor fica perto da média; com muitas, perto do percentual real.

Corpus (trechos de até 50 palavras)	% números fake	% números true	AUC isolada
Fake.br	2,13	3,12	0,61
FakeRecogna 2020–21	3,40	3,79	0,56
Corpus externo	2,41	5,21	0,76

Modelo (validação externa)	F1
Só tamanho (controle)	49,7
Só números (contagem / pct / pct_suave / categorias)	69,2 / 68,9 / 68,9 / 69,5
TF-IDF [base]	90,5
TF-IDF + pct_suave	90,5
TF-IDF + categorias de números	90,5
TF-IDF com dígitos mascarados (2026 → 0000)	90,7 (mas -3,8 em fonte nova)

Conclusão: a hipótese é **verdadeira como observação** (true têm mais números nos três corpora, e no externo em cada uma das quatro fontes), mas a feature **não acrescenta nada** ao TF-IDF.

Por quê: o SVM deu peso ~0 a ela (-0,01 contra 0,20 de média por termo). O TF-IDF já contém essa informação: tokens como "2026", "14h30", "milhões". **Decisão: não entra no modelo.**

Lição para a banca: um sinal pode ser real e mesmo assim redundante com o que o modelo já vê.

7. Escolha do modelo e avaliação final

A escolha (feita antes de olhar o teste)

Candidato	Validação	Fonte nova 1	Fonte nova 2
palavras (1,2) [base]	90,5	80,1	80,4
caracteres char_wb(2,5)	91,4	80,2	83,0
palavras + caracteres sem lowercase	92,3	76,6	81,8
e5-small + regressão logística	91,8	não medido	não medido

Quatro motivos:

1. Está no grupo de topo da validação (empate técnico com os outros três).
2. É o **único do topo que nunca perdeu para a base em fontes novas**.
3. Entre empatados, é o mais simples: sem torch, sem modelo de 470 MB, com o treino misto e com medida de robustez.
4. Faz sentido para boatos: n-gramas de caracteres capturam grafia, pontuação e erros de digitação.

Pré-registro

Antes de ler qualquer rótulo, ficou escrito: os 8 métodos avaliados, as métricas e a regra de leitura (**o escolhido não muda com o resultado**; diferenças dentro dos ICs são empate). Foi coletado também um 2º teste (77 itens, 28/09 a 05/10, semana da eleição).

Resultado (avaliado uma única vez)

Método	Teste 1 (39)	Teste 2 (77)	1 + 2 (116)	Rec. fake	Rec. true
Só Fake.br (antigo)	94,2	84,9	88,8 [81–95]	80,6	95,3
Fake.br + FR (antigo)	88,5	87,6	88,2 [80–94]	74,2	97,6
TF-IDF palavras [base]	88,0	93,9	91,7 [85–97]	77,4	100
TF-IDF caracteres [escolhido]	88,0	98,1	94,2 [89–99]	83,9	100
Palavras + caracteres	84,6	96,1	91,7 [85–97]	77,4	100
e5-small + LogReg	88,0	94,2	91,9 [85–97]	80,6	98,8
Só números (E8)	61,4	69,8	67,3 [58–76]	87,1	62,4
Palavras + números (E8)	88,0	93,9	91,7 [85–97]	77,4	100

- **Matriz do escolhido:** 85 de 85 true corretas; 26 de 31 fake corretas; **5 erros, todos fake → true**.
- Os ICs se sobrepõem com todos os modelos com corpus externo (~92) e até com os antigos (~88): o teste **confirma a direção** da validação, mas **não prova vencedor**.
- No teste 1, o modelo só Fake.br fica em primeiro (94,2); no teste 2, em último (84,9). Com 14 fake, uma previsão vale ~4 pontos: é instabilidade de amostra pequena.
- **Os 5 erros** são boatos escritos como notícia ("ZANIN ASSUME O TSE... tomou posse") ou como narrativa ("Ele comprou dois assentos no avião..."), sem CAIXA ALTA nem "URGENTE": o modelo aprende estilo, não fatos.

8. Como o modelo funciona por dentro

O caminho de um texto

texto → primeiras 50 palavras → pedaços de 2 a 5 letras (char_wb) → vetor TF-IDF de 200 mil posições
→ soma ponderada do LinearSVC → score ≥ 0 ? TRUE : FAKE

- **char_wb**: "urgente" vira "u", "ur", "urg", "urge", "rgen", "gente"... sempre dentro de cada palavra (o espaço marca a borda). Diferente do TF-IDF de palavras, **mantém a pontuação**.
- **TF**: $1 + \log(\text{contagem})$ (sublinear): repetir um pedaço pesa, mas com retorno decrescente.
- **IDF**: pedaço raro pesa mais que pedaço comum.
- **LinearSVC**: um peso por pedaço; score = soma(peso × valor) + constante. Score é distância da fronteira, **não probabilidade**.
- **class_weight='balanced'**: erros na classe menor pesam mais no treino.

O que ele aprendeu (pesos reais, analisados em 06/10)

Mais típicos de FAKE	Peso	Mais típicos de TRUE	Peso
"! " (exclamação)	-4,23	" a " (artigo)	+3,65
travessão solto " - "	-2,5 a -3,1	" o " (artigo)	+3,04
" [", " *" (colchete, asterisco)	-2,1 a -2,5	". " (frase terminada)	+2,29
espaço antes de ".", " e ", "	-1,8 a -2,4	" (" (parênteses)	+1,91
"post", "postag"	-1,4 a -1,6	"disse"	+1,3 a +1,8
" eu ", "mos " (1ª pessoa)	-1,5	" de ", " da ", " do "	+1,2 a +1,5
" pra "	-1,40	"</s>" (artefato!)	+1,28
"!!"	-1,30	"casos"	+1,10
"menti", "storc", " omit"	-1,3	"nesta"	+0,66

Leitura: pontuação e formatação pesam mais que qualquer palavra. Boato tem exclamação, travessão solto, asterisco e espaço antes da vírgula. Notícia tem frase completa com artigo, parênteses ("nesta quarta-feira (1º)") e "disse".

Achado de 06/10: o artefato </s>. É a marca de fim de texto do resumidor automático do FakeRecogna. Aparece em **14.003 das 26.400 true e em nenhuma fake**, e virou um peso forte de TRUE.

No uso real ninguém cola </s>, então a previsão não muda. Mas é prova concreta de que parte do que o modelo aprende com o FakeRecogna é estilo do resumidor. Removê-lo seria uma melhoria e exigiria um teste novo.

Também: vocabulário de agência de checagem ("distorce", "omite", "mentira", "postagem") pesa como FAKE, e "lula" (-1,16) é atalho de assunto da época.

Ficha do modelo escolhido

TfidfVectorizer(analyzer='char_wb', ngram_range=(2,5), max_features=200000, sublinear_tf=True)
→ LinearSVC(C=1.0, class_weight='balanced', max_iter=20000)

Treino: FakeRecogna 2020-21 (4.001 + 4.001) + corpus externo treino (645 + 1.349), cada texto cortado em 30, 50 e 100 palavras = 29.988 trechos

Uso: primeiras 50 palavras; score ≥ 0 → true

Reprodutibilidade (06/10): treinado do zero com treinar_do_zero.py, o modelo saiu idêntico ao original: mesmo vocabulário, mesmas previsões, F1 de validação 91,43.

9. Limitações (saiba falar de todas)

Limitação	Evidência	Consequência
Aprende estilo, não fatos	os 5 erros são boatos com redação de notícia	boato bem escrito passa
Não distingue boato de checagem	vocabulário de agência pesa como FAKE	"É falso que..." vira FAKE
Assinatura de site	E6: ~90 → ~80 em fontes novas	esperar ~80–83 fora das 4 fontes
Atalho de época	fake até jul/2026 × true ago–out/2026	nem validação nem teste detectam
Estilo do resumidor (FakeRecogna)	</s> em 14.003 true, 0 fake	parte do aprendizado é atalho
Teste pequeno	116 itens, 31 fake, 1 do E-farsas	IC de ~10 pontos
Ruído no treino	42 especiais publicitários do G1 como true	não corrigido (modelo congelado)
Seleção otimista	~40 configurações na mesma validação	validação superestima; por isso o teste
Score não calibrado	LinearSVC dá distância, não probabilidade	não dá para dizer "80% de chance"

O que fazer depois (não testado)

- **Teste 3:** notícias publicadas após 05/10, pré-registrado, avaliando só o modelo escolhido sem mudanças.
- Remover os 42 especiais publicitários e o </s> do treino; revalidar.
- Mais boatos do E-farsas em texto; split temporal para medir o atalho de época; calibrar o score.
- Qualquer mudança no modelo exige um teste novo, porque os testes 1 e 2 já foram usados.

10. Perguntas prováveis da banca (com respostas)

Por que vocês não usaram só o Fake.br, que é o dataset de referência?

Porque ele tem dois atalhos: as true são 6× maiores (só o tamanho acerta 94%) e 92,7% das fake vêm de um site. Na E4, com o corpus externo no treino, somar o Fake.br não mudou nada ($87,6 \times 88,3$).

O 94,2 não é sorte?

Pode ter parte de sorte: o IC vai de 89 a 99 e se sobrepõe com outros modelos. Por isso dizemos que o teste confirma a direção da validação, mas não prova vencedor. A estimativa honesta é ~91–94 nas mesmas fontes e ~80–83 em fontes novas.

Por que caracteres e não palavras?

Empataram na validação ($91,4 \times 90,5$), mas caracteres nunca perdeu em fonte nova (até +2,6). Além disso, mantém pontuação, que virou o sinal mais forte.

Por que não o primeiro colocado da validação (92,3)?

Porque ele perdeu 3,5 pontos em fonte nova: as maiúsculas que ele usa parecem ser estilo de cada site.

Por que não embeddings, que são mais modernos?

O e5-small empatou (91,8), mas não tinha medida de robustez entre fontes, exige 470 MB e torch, e não usou o treino misto. Entre empatados, ficamos com o mais simples.

Como garantem que não olharam o teste?

Toda escolha usou a validação; o teste foi descontaminado sem rótulo; a escolha e a regra de leitura foram pré-registradas; o script de avaliação roda uma vez só e se recusa a repetir.

Por que treinar com 30, 50 e 100 palavras?

O produto recebe trechos curtos. Treinado com texto inteiro, o modelo chamava quase todo trecho curto de fake (recall true 0,15%). O misto foi melhor que só 50 nos três tamanhos.

A hipótese dos números estava errada?

Não: true têm mais números ($5,2\% \times 2,4\%$ no externo). Mas o TF-IDF já vê os números, então a feature ganhou peso ~0 e não mudou nada.

Qual o maior defeito do modelo?

Ele aprende estilo, não fatos. Os 5 erros são boatos escritos como notícia. Serve como triagem de "cara de boato", não como checagem.

O modelo é supervisionado?

Sim, o LinearSVC aprende com rótulos fake/true. O TF-IDF antes dele é não supervisionado (não usa o rótulo).

Por que F1 macro e não acurácia?

O corpus externo tem 2× mais true. A acurácia premiaria chutar true; o F1 macro dá peso igual às duas classes.

O que o modelo realmente olha?

Principalmente pontuação e formatação: exclamação, travessão solto, asterisco e espaço antes da vírgula indicam boato; artigos, parênteses e "disse" indicam notícia.

11. Cola de uma página

Para lembrar	Número
Modelo antigo na validação externa	82,9
Só trocando os dados (fr2021 + ext)	90,5 (+7,5)
Só trocando o modelo (char_wb)	91,4 (+0,9, empate)
Teste final, F1 macro	94,2 [89–99]
Recall true / recall fake no teste	100% (85/85) / 83,9% (26/31)
Fontes novas (E6)	~80–83
Validação externa	855 itens (277 fake, 578 true)
Corpus externo total	2.849 itens (70% treino / 30% val)
Testes	39 + 77 = 116 itens
Treino final	8.002 FakeRecogna + 1.994 externo → $\times 3 = 29.988$ trechos
Configurações testadas na validação	~40
Empate técnico	< 1–2 pontos
Entrada do produto	até 50 palavras; score $\geq 0 \rightarrow$ true
Versão do scikit-learn	1.6.1
</s> no FakeRecogna	14.003 true, 0 fake

Três frases para a apresentação:

1. "O que mais melhorou o modelo foram dados no formato certo, não um algoritmo mais sofisticado."
2. "Escolhemos tudo na validação e avaliamos o teste uma única vez, com pré-registro."
3. "O modelo reconhece estilo de boato, não verifica fatos: um boato bem escrito passa."